

AI for Food Waste Reduction

*Gıda İsrafının Azaltılmasında Yapay Zeka: Talep Tahmini ve
Dinamik İndirimleme*

AI in Marketing Capstone

Literatür Taraması, Veri Araştırması ve Teknoloji İncelemesi

Osman Furkan Erkan

Nermin Kılıçarslan

Dilara Kuyar

Ahsen Nisa Sarıkaya

Bölüm 1 — Literatür Taraması (Literature Review)

1. Giriş

Süpermarket ve restoran gibi gıda perakendecileri, hangi ürünlerin yakın vadede satılamayacağını önceden kestiremedikleri için önemli miktarda gıda israfıyla karşılaşmaktadır. Bu belirsizlik yalnızca operasyonel bir stok yönetimi sorunu değil, aynı zamanda bir pazarlama problemidir: talep doğru öngörülemediğinde doğru ürüne doğru zamanda doğru indirim ya da promosyon uygulanamamakta, bu da hem gelir kaybına hem de fiyata duyarlı müşteri segmentinde memnuniyetsizliğe ve sepet terkine yol açmaktadır. Birleşmiş Milletler Çevre Programı'nın 2024 Gıda İsrafı Endeksi Raporu'na göre 2022 yılında küresel ölçekte 1,05 milyar ton gıda israf edilmiştir; bu israfın büyük kısmı (%60) hane halkı düzeyinde, %28'i yiyecek-içecek hizmetlerinde ve %12'si perakende aşamasında gerçekleşmektedir (UNEP, 2024). Perakendenin payı oransal olarak küçük görünse de, mutlak miktar (2022'de yaklaşık 131 milyon ton) ve perakendecinin bu israfı doğrudan etkileme/azaltma gücü (fiyatlandırma ve promosyon kararları üzerinden) projeyi motive etmektedir; ayrıca literatürde ABD'ye özgü aktarılan bazı tahminler, market zincirlerinin israfının milyarlarca pound seviyesinde olduğunu öne sürmektedir (Vadakepatt vd., 2021; Weigel, 2020'den aktaran Syed vd., 2024) — bu rakam ikincil bir kaynaktan aktarıldığı için ihtiyatla değerlendirilmelidir.

Bu projenin pazarlama bağlamı şu şekilde tanımlanmaktadır: hedef müşteri, hem (a) fiyata duyarlı, sadakat uygulaması üzerinden alışveriş yapan son tüketiciler hem de (b) mağaza içi fiyatlandırma ve promosyon kararlarını veren kategori/pazarlama ekipleridir. Kanal, mobil sadakat uygulaması bildirimleri ve elektronik raf etiketleri/uygulama içi "günün fırsatı" alanlarıdır. Müşteri yolculuğunda odak nokta, tekrar eden (rutin) satın alma ve sepete ekleme kararı anıdır; burada doğru zamanlanmış bir indirim teklifi hem israfı azaltabilir hem de dönüşüm oranını artırabilir. Bu literatür taramasının araştırma sorusu şudur: yapılandırılmış (tablo) perakende satış verisiyle eğitilen makine öğrenmesi tabanlı talep tahmini modelleri, israf riski taşıyan ürünler için dinamik indirim kararlarını ne ölçüde iyileştirebilir ve bu yaklaşım hangi pazarlama KPI'larını etkiler? Bu soruyu yanıtlamak için hem akademik talep tahmini/dinamik fiyatlandırma literatürünü hem de doğrudan gıda israfı bağlamındaki çalışmaları incelemek gerekmektedir; çünkü model seçimi (örn. gradient boosting mi, derin öğrenme mi) doğrudan tahmin doğruluğunu, dolayısıyla indirim kararlarının isabetini ve nihayetinde pazarlama sonuçlarını belirlemektedir.

2. Organizasyon

Literatür, konuya en uygun şekilde tematik olarak organize edilmiştir. Üç ana tema belirlenmiştir: (1) perakende talep tahmininde makine öğrenmesi yaklaşımları, (2) gıda israfına özgü dinamik fiyatlandırma ve promosyon çalışmaları ve (3) gradient boosting yöntemlerinin (XGBoost/LightGBM) tablo verisi üzerindeki karşılaştırmalı performansı. Bu tematik yapı, projenin hem "talebi doğru tahmin etme" hem de "tahmine dayalı indirim kararı üretme" olmak üzere iki aşamalı mimarisiyle örtüşmektedir.

3. Özet ve Sentez

3.1 Tema 1 — Perakende Talep Tahmininde Makine Öğrenmesi

Andrade ve Cunha (2023), büyük ölçekli, dağınık (disaggregated) perakende talep tahmini için gradient boosting tabanlı bir yaklaşım önermiş; yöntemin çok sayıda SKU (stok tutma birimi) ve mağaza kombinasyonunda geleneksel istatistiksel yöntemlere kıyasla daha iyi ölçeklenebilirlik ve doğruluk sağladığını göstermiştir. Wang vd. (2023), mekânsal-zamansal (spatial-temporal) özellikleri gradient boosting modellerine ekleyerek kısa vadeli ürün düzeyinde talep tahmininin, e-ticaretin büyümesiyle artan SKU

çeşitliliği karşısında dahi yüksek doğrulukla yapılabileceğini ortaya koymuştur. Buna karşın, gıda talebine özgü bir çalışmada Kumar ve arkadaşlarının (aktaran, Demand Forecasting for Perishable Goods in Retail Using Big Data Analytics çalışması) sebze talebi tahmininde LSTM ve destek vektör regresyonunun (SVR), belirli senaryolarda gradient boosting yöntemlerinden daha iyi sonuç verdiğini bulmuştur; bu da model seçiminin ürün kategorisine ve veri hacmine göre değişebileceğini göstermektedir.

3.2 Tema 2 — Gıda İsrafına Özgü Dinamik Fiyatlandırma

Felix (2018), Twente Üniversitesi yüksek lisans tezinde perakende gıda israfını azaltmak amacıyla talep tahmini teknikleri ile dinamik fiyatlandırma stratejilerini birlikte karşılaştırmış ve iki bileşenin (tahmin + fiyatlandırma kuralı) birlikte ele alınmasının tek başına daha iyi tahminden daha fazla israf azaltımı sağladığını savunmuştur; bu bulgu, projenin "tahmin + otomatik indirim önerisi" mimarisini doğrudan desteklemektedir. Benzer şekilde, Abdullah, Shaikh ve Almusharraf (2025), "Towards a Sustainable Retail Food Chain: Artificial Intelligence Driven Dynamic Pricing and Promotions for Food Waste Reduction" başlıklı çalışmalarında Gradient Boosting, SVR, Karar Ağacı, KNN, Rastgele Orman ve Yapay Sinir Ağları modellerini karşılaştırmış; Gradient Boosting'in en düşük hata oranlarıyla (MAE ve RMSE) ve en yüksek R^2 değeriyle en iyi performansı gösterdiğini bulmuştur. Syed vd. (2024) ise veri odaklı dijital dönüşüm çerçevesinde market perakendeciliğinde yapay zeka destekli dinamik fiyatlandırmanın israfı azaltma ve kârlılığı artırma potansiyelini vurgulamış, düşük perakende kâr marjlarının (%0,2–%6,1 arası) israf kaynaklı kayıplara karşı özellikle hassas olduğunu belirtmiştir.

3.3 Tema 3 — Gradient Boosting Yöntemlerinin Karşılaştırmalı Performansı

Tablo verisi üzerinde XGBoost ve LightGBM'i karşılaştıran teknik incelemeler (XGBoosting.com, t.y.; Bohrium, 2026), LightGBM'in yaprak-bazlı (leaf-wise) büyüme stratejisi ve histogram tabanlı bölme yöntemleri sayesinde büyük veri setlerinde genellikle daha hızlı eğitim süresi sunduğunu, buna karşın XGBoost'un seviye-bazlı (level-wise) büyümesi nedeniyle daha kararlı ve yorumlanabilir sonuçlar (SHAP değerleriyle daha güçlü açıklanabilirlik) sağladığını göstermektedir. Bu karşılaştırma, projede iki algoritmanın da denenip hangisinin veri setinin boyutu ve kategorik değişken yoğunluğu için daha uygun olduğunun ampirik olarak belirlenmesi gerektiğine işaret etmektedir.

Sentez

Kaynaklar bir arada değerlendirildiğinde literatür, üç önemli çıkarım sunmaktadır. Birincisi, yapılandırılmış perakende verisinde gradient boosting aileleri (XGBoost, LightGBM), derin öğrenme yöntemlerine kıyasla genellikle benzer veya daha iyi doğruluk sağlarken çok daha az hesaplama kaynağı gerektirmekte ve daha yorumlanabilir olmaktadır — bu da küçük-orta ölçekli bir capstone projesi için pratik bir avantajdır. İkincisi, yalnızca talep tahmini yapmak yeterli değildir; israfı azaltmak isteyen çalışmaların tamamı tahmini bir fiyatlandırma/promosyon kuralına bağlamaktadır, bu da projenin "tahminden otomatik indirim önerisine" uzanan uçtan uca tasarımı doğrulamaktadır. Üçüncüsü, kaynaklar arasında yöntem seçiminde fikir birliği tam değildir — LSTM/SVR bazı sebze/meyve senaryolarında öne çıkabilmektedir — bu nedenle proje, model karşılaştırmasını (Bölüm 4'te ayrıntılandırılan Teknoloji İncelemesi'nde) ampirik olarak doğrulamalıdır.

4. Pazarlama Açısından İlgi ve Boşluk

Mevcut literatür, talep tahmini doğruluğunu artırma (RMSE/MAE gibi teknik metriklerle) konusunda oldukça olgunlaşmıştır ve dinamik fiyatlandırmanın israfı azalttığını göstermiştir. Ancak incelenen çalışmaların büyük kısmı, tahmin/fiyatlandırma performansını yalnızca operasyonel metriklerle (israf miktarı, kâr marjı) değerlendirmekte; müşteri tarafındaki pazarlama sonuçlarını — örneğin indirim bildirimine tepki oranı, sadakat uygulaması etkileşimi, tekrar satın alma/retention oranı — sistematik olarak ele almamaktadır. Bu, projenin yanıtladığı temel boşluktur: model çıktısını yalnızca bir "öneri" olarak değil, mağaza-ürün düzeyinde

kişiselleştirilmiş, ölçülebilir bir pazarlama aksiyonuna (hedefli indirim bildirimi) dönüştürmek ve bu aksiyonun israf azaltımı kadar müşteri davranışı KPI'larını da nasıl etkilediğini değerlendirmektir.

5. Sonuç

Literatür taraması, gradient boosting tabanlı talep tahmininin yapılandırılmış perakende verisinde güçlü ve yorumlanabilir bir temel sunduğunu, dinamik fiyatlandırma ile birleştirildiğinde gıda israfını azaltmada etkili olduğunu göstermektedir. Bu bulgular, projenin XGBoost/LightGBM tabanlı bir talep tahmini modeli kurup bunu otomatik indirim önerisi mantığına bağlama yaklaşımını doğrudan desteklemektedir. Proje tasarımı açısından çıkarım şudur: model, yalnızca teknik doğruluk metrikleriyle değil, indirimin dönüşüme ve müşteri elde tutmaya etkisiyle de değerlendirilmelidir.

6. Kaynakça

- Abdullah, N., Shaikh, A. K., & Almusharraf, A. (2025). Towards a sustainable retail food chain: Artificial intelligence driven dynamic pricing and promotions for food waste reduction. *Journal of Posthumanism*, 5(6), 571–588. <https://doi.org/10.63332/joph.v5i6.2073>
- Andrade, L. A. C. G., & Cunha, C. B. (2023). Disaggregated retail forecasting: A gradient boosting approach. *Applied Soft Computing*, 141, 110283. <https://doi.org/10.1016/j.asoc.2023.110283>
- Felix, P. G. (2018). Data-driven retail food waste reduction: A comparison of demand forecasting techniques and dynamic pricing strategies (Yüksek lisans tezi). University of Twente. <https://essay.utwente.nl/76380/>
- Syed, T. A., Aslam, H., Bhatti, Z. A., Mehmood, F., & Pahuja, A. (2024). Dynamic pricing for perishable goods: A data-driven digital transformation approach. *International Journal of Production Economics*, 277, 109405. <https://doi.org/10.1016/j.ijpe.2024.109405>
- UNEP. (2024). Food Waste Index Report 2024: Think eat save — Tracking progress to halve global food waste. United Nations Environment Programme.
- Wang, J., Chong, W. K., Lin, J., & Hedenstierna, C. P. T. (2023). Retail demand forecasting using spatial-temporal gradient boosting methods. *Journal of Computer Information Systems*, 64(5), 652–664. <https://doi.org/10.1080/08874417.2023.2240753>

Bölüm 2 — Veri Araştırması (Data Research)

1. Giriş

Bu bölümün pazarlama hedefi, israf riski taşıyan ürün-şube kombinasyonlarını haftalar öncesinden tespit edip bu ürünlere yönelik hedefli indirim kararlarını desteklemektir. Bu amaçla geçmiş haftalık satış/talep verisi, ürün ve dağıtım merkezi (şube) bilgisiyle birlikte gereklidir; çünkü model, yalnızca genel bir talep eğilimi değil, her ürün-şube kombinasyonuna özgü, mevsimsellik ve geçmiş promosyonlardan etkilenen bir talep tahmini üretmelidir. Seçilen veri seti, hem talebi tahmin etmeye hem de checkout_price/base_price alanları üzerinden geçmiş indirim oranlarını hesaplayarak "hangi indirim seviyesi talebi ne kadar hareketlendiriyor" sorusuna görgül bir yanıt bulmaya imkân tanıdığı için projenin pazarlama KPI'larıyla (satış devri oranı, indirim etkinliği) doğrudan bağlantılıdır.

2. Veri Kaynağı ve Kapsamı

Çalışmada kullanılan veri seti, Kaggle üzerinde yayımlanan "Food Demand Forecasting" veri setidir (kannanaikkal/food-demand-forecasting). Veri, kamuya açık ikincil bir kaynak olup gerçek bir yemek teslimat şirketinin anonimleştirilmiş operasyonel kayıtlarına dayanmaktadır.

- Erişim yöntemi: CSV dosyalarının doğrudan indirilmesi
- Format: Birbiriyle ilişkili üç tablo (haftalık talep, dağıtım merkezi bilgisi, ürün-fiyat bilgisi)
- Boyut ve kapsam: 145 hafta boyunca yaklaşık 456 bin talep kaydı; 77 dağıtım merkezi; 4 farklı mutfağa ait 14 kategori altında 51 ürün
- Granülerite: hafta × ürün × dağıtım merkezi kırılımında sipariş adedi (num_orders)
- Anahtar değişkenler: center_id, meal_id, checkout_price, base_price, emailer_for_promotion, homepage_featured, num_orders

Bu veri seti, projenin hedef müşteri/kanal bağlamıyla doğrudan örtüşmektedir: her satır bir "mağaza/dağıtım merkezi" ve bir "ürün" için haftalık talebi temsil ettiğinden, model çıktısı doğrudan mağaza düzeyinde bir indirim önerisine dönüştürülebilir. Projenin nihai hedefi olan kişiselleştirilmiş indirim ise, motorun marketin kendi sadakat/müşteri verisiyle entegre edilmesiyle mümkün olur; kamuya açık bu veri seti, müşteri kimliği içermediğinden motorun mağaza düzeyinde çalıştığını kanıtlama işlevi görür. checkout_price ile base_price arasındaki fark üzerinden geçmişte uygulanmış indirim oranı türetilbildiği için, model yalnızca "talep ne olacak" sorusuna değil, "bu ürüne uygulanan indirim geçmişte talebi ne kadar artırdı" sorusuna da kısmen yanıt verebilecek, bu da dinamik indirim öneri motorunun kural tabanının gerçek satış verisine dayandırılmasını sağlayacaktır.

3. Veri Kalitesi, Gizlilik ve Sınırlılıklar

Veri setinin belgelenen bir avantajı, üç tablonun sorunsuz şekilde birleştirilebilmesi ve eksik (missing) değer içermemesidir; bu, ön işleme sürecini basitleştirmektedir. Yine de aşağıdaki kalite ve kapsam sınırlılıkları göz önünde bulundurulmalıdır:

- Hedef değişken çarpıklığı: bazı ürün-şube kombinasyonlarının talebi çok düşük/seyrekle olabilir, bu da düşük hacimli SKU'larda tahmin belirsizliğini artırabilir.
- Zamansal kapsam sınırlılığı: veri 145 haftayla sınırlıdır; çok yıllık mevsimsellik veya nadir görülen talep şokları (örn. tatil dönemleri, ekonomik krizler) yeterince temsil edilmeyebilir.

- Coğrafi/bağlamsal genellenebilirlik: veri belirli bir yemek teslimat platformuna aittir; geleneksel bir süpermarket zincirinin taze gıda talebiyle davranışsal farklılıklar gösterebilir, bu nedenle bulgular genel süpermarket bağlamına dikkatli şekilde uyarlanmalıdır.
- Gizlilik: veri anonimleştirilmiş, toplulaştırılmış işlem düzeyinde olup bireysel müşteri kimliği içermemektedir; bu nedenle KVKK/GDPR anlamında kişisel veri işleme riski düşüktür. Ancak proje ileride gerçek bir sadakat uygulaması verisiyle genişletilirse, müşteri düzeyinde kişiselleştirme için açık rıza, anonimleştirme ve veri minimizasyonu ilkeleri uygulanmalıdır.
- Etiketleme/güncellik: veri seti statiktir (geçmişe dönük, tek seferlik yayınlanmış); gerçek zamanlı bir üretim sisteminde veri tazeliği (freshness) ayrıca sağlanmalıdır.

4. Keşifsel Analiz ve Pazarlama İlgörüleri

Veri setinin yapısı üzerinden yapılan ön inceleme, aşağıdaki pazarlama açısından anlamlı örüntülerin beklenebileceğini göstermektedir (nihai sayısal analiz ve görselleştirmeler proje uygulama aşamasında tamamlanacaktır):

- Promosyon etkisi: `emailer_for_promotion` ve `homepage_featured` değişkenleri aktif olduğunda `num_orders` değerinde belirgin bir artış beklenmektedir; bu, hangi promosyon kanalının hangi ürün kategorisinde daha etkili olduğunu ölçmeye imkân tanır ve doğrudan "kampanya etkinliği" KPI'sıyla ilişkilidir.
- Fiyat esnekliği: `checkout_price/base_price` oranı ile `num_orders` arasındaki ilişki incelenerek, hangi ürün kategorilerinin indirim karşs daha esnek (fiyat değişimine duyarlı) talep gösterdiği belirlenebilir; bu bilgi, otomatik indirim motorunun hangi ürünlere öncelik vereceğini belirlemesine yardımcı olur.
- Mevsimsellik ve haftalık döngüler: 145 haftalık zaman serisi, ürün kategorisi bazında mevsimsel dalgalanmaları ortaya koyabilir; bu, indirim zamanlamasının (örn. hafta sonu öncesi) optimize edilmesine katkı sağlar.
- Şube (dağıtım merkezi) düzeyinde heterojenlik: 77 farklı dağıtım merkezi arasında talep düzeyi ve promosyona duyarlılık farklılık gösterebilir; bu, tek bir genel model yerine şube/bölge bazlı kişiselleştirilmiş indirim stratejilerinin gerekliliğine işaret eder.

Bu örüntüler doğrudan pazarlama metrikleriyle ilişkilendirilebilir: promosyon etkisi ve fiyat esnekliği bulguları dönüşüm oranı ve indirim kullanım (redemption) oranını öngörmeye kullanılabilir; şube düzeyinde heterojenlik bulgusu ise hedefleme/segmentasyon stratejisinin ürün geri kazanım (sell-through) oranı ve israf azaltımı üzerindeki etkisini optimize etmeye yardımcı olacaktır.

5. Sonuç

İncelenen veri seti, eksik değer içermemesi, üç tablonun ilişkisel olarak birleştirilebilmesi ve hem talep hem de fiyat/promosyon bilgisini bir arada sunması nedeniyle projenin ikinci aşama (modelleme) için uygun olduğu değerlendirilmektedir. Veri, `checkout_price` ve `base_price` üzerinden indirim oranının doğrudan hesaplanmasına imkân tanıdığından, hem talep tahmini hem de dinamik indirim önerisi bileşenlerinin aynı veri kümesi üzerinde geliştirilmesini mümkün kılmaktadır. Bununla birlikte, verinin belirli bir platforma ve sınırlı bir zaman aralığına ait olması, bulguların genel süpermarket bağlamına aktarılırken temkinli yorumlanmasını gerektirmektedir.

6. Kaynakça

Kaggle. Food Demand Forecasting veri seti (kannanaikkal/food-demand-forecasting).
<https://www.kaggle.com/datasets/kannanaikkal/food-demand-forecasting>

UNEP. (2024). Food Waste Index Report 2024: Think eat save — Tracking progress to halve global food waste. United Nations Environment Programme.

Bölüm 3 — Teknoloji İncelemesi (Technology Review)

1. Giriş

Bu bölümde, gıda israfını azaltmaya yönelik pazarlama/fiyatlandırma projesinde kullanılacak temel yapay zeka teknolojisi olarak gradient boosting tabanlı makine öğrenmesi modelleri (özellikle XGBoost ve LightGBM) değerlendirilmektedir. Teknoloji incelemesi önemlidir çünkü model seçimi yalnızca teknik doğruluğu değil; eğitim süresini, yorumlanabilirliği ve dolayısıyla pazarlama ekibinin modele güvenip önerilen indirim kararlarını uygulamaya koyma isteğini doğrudan etkilemektedir.

2. Teknoloji Genel Bakışı

Gradient boosting, birden fazla zayıf öğrenici karar ağacının ardışık olarak birleştirilmesiyle güçlü bir tahmin modeli oluşturan bir topluluk (ensemble) öğrenme yöntemidir. XGBoost ve LightGBM, bu ailenin en yaygın kullanılan iki açık kaynak uygulamasıdır ve her ikisi de yapılandırılmış (tablo) veride öne çıkmaktadır. XGBoost seviye-bazlı (level-wise) ağaç büyütme stratejisi kullanırken, LightGBM yaprak-bazlı (leaf-wise) büyüme ile histogram tabanlı bölme, Gradient-based One-Side Sampling (GOSS) ve Exclusive Feature Bundling (EFB) tekniklerini birleştirerek büyük ve seyrek (sparse) veri setlerinde eğitim süresini önemli ölçüde kısaltmaktadır (XGBoosting.com, t.y.; Bohrium, 2026). Pazarlama ve perakende bağlamında bu teknolojiler yaygın olarak talep tahmini, churn (müşteri kaybı) tahmini, öneri sistemleri ve fiyat esnekliği modellemesi gibi görevlerde kullanılmaktadır.

3. Pazarlama Projesi ile İlişkisi

Bu teknoloji, projenin çekirdek pazarlama sorununu doğrudan çözmektedir: her ürün-şube kombinasyonu için haftalık talep tahmini üreterek, düşük talepli/israf riski taşıyan ürünlerin erken tespitini sağlamaktadır. Bu tahmin, pazarlama iş akışında şu noktalara yerleşmektedir: (a) kategori yönetimi/fiyatlandırma ekibi için haftalık "risk listesi" oluşturma, (b) sadakat uygulaması üzerinden hedefli, kişiselleştirilmiş indirim bildirimi tetikleme ve (c) kampanya sonrası ölçümleme için bir referans (baseline) talep tahmini sağlama. Böylece teknoloji, yalnızca bir tahmin aracı değil, aynı zamanda dinamik fiyatlandırma ve hedefleme kararlarını besleyen bir pazarlama karar destek sistemi işlevi görmektedir.

4. Karşılaştırma ve Değerlendirme

Proje kapsamında değerlendirilen başlıca alternatifler XGBoost, LightGBM ve derin öğrenme tabanlı yöntemlerdir (örn. LSTM). Değerlendirme, yalnızca genel teknik metriklerle değil, projenin pazarlama bağlamına uygun kriterlerle yapılmıştır:

Kriter	XGBoost	LightGBM	LSTM (Derin Öğrenme)	Projeye Uygunluk
Doğruluk (yapılandırılmış veride)	Yüksek	Yüksek, büyük veride avantajlı	Değişken, veri hacmine bağımlı	GBM tercih edilir
Eğitim süresi (~456K satır)	Orta	Hızlı (GOSS/EFB)	Yavaş, GPU gerektirebilir	LightGBM avantajlı
Yorumlanabilirlik (SHAP vb.)	Güçlü	Güçlü	Zayıf/kutu-siyah	GBM tercih edilir

Kriter	XGBoost	LightGBM	LSTM (Derin Öğrenme)	Projeye Uygunluk
Veri gereksinimi	Orta ölçekte iyi çalışır	Orta-büyük ölçekte iyi çalışır	Büyük veri gerektirir	GBM tercih edilir
Entegrasyon/bakım maliyeti	Düşük-orta	Düşük-orta	Yüksek	GBM tercih edilir

Değerlendirme kriterleri arasında yalnızca RMSE/MAE gibi genel teknik metrikler değil; pazarlama ekibinin modele güvenip önerilen indirimi uygulamaya koyma olasılığını etkileyen yorumlanabilirlik, gerçek zamanlı haftalık yeniden eğitim döngüsüne uygun eğitim hızı ve düşük entegrasyon maliyeti de dikkate alınmıştır. Bu kriterler ışığında, ~456.000 satırlık orta ölçekli tablo verisi için gradient boosting ailesi (özellikle LightGBM'in hız avantajı ile XGBoost'un yorumlanabilirlik avantajının ikisinin de test edilmesi) derin öğrenmeye kıyasla daha uygun bulunmuştur; bu sonuç Bölüm 1'deki literatür bulgularıyla da tutarlıdır.

5. Kullanım Örnekleri

Andrade ve Cunha (2023), büyük ölçekli perakende ortamlarında gradient boosting tabanlı dağıtık talep tahmininin çok sayıda SKU'da tutarlı doğruluk sağladığını göstermiştir; bu, projenin 51 ürün kategorisi × 77 şube ölçeğiyle doğrudan karşılaştırılabilir bir senaryodur. "Towards a Sustainable Retail Food Chain" (2025) çalışmasında Gradient Boosting'in gıda israfı bağlamında SVR, Karar Ağacı ve Rastgele Orman'a kıyasla en düşük hata oranına ulaştığı bulgusu, doğrudan projenin model seçimini desteklemektedir. Perakende öneri ve fiyatlandırma sistemlerine yönelik bir teknik karşılaştırmada, LightGBM'in yüksek hacimli, seyrek kullanıcı-etkileşim verisinde hızlı eğitim döngüleri sunduğu, XGBoost'un ise gürültülü verilerde düzenleme (regularization) sayesinde daha sağlam sonuçlar verdiği aktarılmaktadır (Programming Insider, 2025); bu da projede iki modelin de mağaza-ürün verisiyle test edilip karşılaştırılmasının gerekçesini oluşturmaktadır.

6. Sınırlılıklar, Riskler ve Fırsatlar

Seçilen teknolojinin proje bağlamındaki başlıca riskleri ve sınırlılıkları şunlardır:

- Önyargı (bias) riski: geçmiş promosyon verisi belirli ürün/şube kombinasyonlarında yetersiz temsil edilmişse, model bu kombinasyonlar için güvenilir olmayan tahminler üretebilir; bu durum bazı şubelerde adaletsiz indirim dağılımına yol açabilir.
- Aşırı otomasyon riski: tamamen otomatik indirim kararları, marka fiyat algısını (fiyat istikrarsızlığı, "her zaman indirimde" algısı) olumsuz etkileyebilir; bu nedenle insan gözetimi (kategori yöneticisi onayı) önerilmektedir.
- Üçüncü taraf platform bağımlılığı: veri seti belirli bir platforma aittir; gerçek bir süpermarket zincirine uygulanmadan önce modelin yeniden kalibre edilmesi gerekir.
- Açıklanabilirlik ihtiyacı: pazarlama ekibinin önerilen indirimlere güvenmesi için SHAP gibi araçlarla model çıktısının nedenini açıklayabilmek kritik önemdedir.

Buna karşın, fırsatlar arasında modelin zamanla gerçek indirim-dönüşüm geri bildirimiyle (kapalı döngü öğrenme) sürekli iyileştirilmesi, şube bazlı kişiselleştirme yoluyla bölgesel talep farklılıklarına uyum sağlanması ve sadakat uygulaması verisiyle zenginleştirilerek müşteri segmentine özel indirim kişiselleştirmesine genişletilmesi yer almaktadır.

7. Sonuç

Teknoloji incelemesi, gradient boosting tabanlı modellerin (XGBoost/LightGBM), projenin ~456K satırlık orta ölçekli, yapılandırılmış perakende talep verisi için hem doğruluk hem de yorumlanabilirlik-hız dengesi

açısından en uygun teknoloji olduğunu doğrulamaktadır. Bu yaklaşım, literatür taramasındaki bulgularla tutarlı olup, düşük talepli/riskli ürünler için otomatik dinamik indirim önerisi üretme hedefine pratik ve ölçülebilir bir yol sunmaktadır. Başarıyla uygulanması hâlinde bu teknoloji, israf kaynaklı gelir kaybının azaltılması, indirimli ürünlerde satış devri oranının artırılması ve sadakat uygulaması üzerinden müşteri etkileşiminin güçlendirilmesi gibi somut pazarlama değerleri yaratabilir.

8. Kaynakça

- Abdullah, N., Shaikh, A. K., & Almusharraf, A. (2025). Towards a sustainable retail food chain: Artificial intelligence driven dynamic pricing and promotions for food waste reduction. *Journal of Posthumanism*, 5(6), 571–588. <https://doi.org/10.63332/joph.v5i6.2073>
- Andrade, L. A. C. G., & Cunha, C. B. (2023). Disaggregated retail forecasting: A gradient boosting approach. *Applied Soft Computing*, 141, 110283.
- Bohrium. (2026). XGBoost vs LightGBM: 2026 comparison with benchmarks [Teknik blog]. <https://www.bohrium.com/en/blog/tutorials/xgboost-vs-lightgbm/>
- Programming Insider. (2025). XGBoost vs. LightGBM (and CatBoost) for retail recommendation models: A technical benchmark [Teknik blog]. <https://programminginsider.com/xgboost-vs-lightgbm-and-catboost-for-retail-recommendation-models-a-technical-benchmark/>
- XGBoosting.com. (t.y.). XGBoost vs LightGBM [Teknik referans]. <https://xgboosting.com/xgboost-vs-lightgbm/>

Genel Kaynakça (Tüm Bölümler)

- Abdullah, N., Shaikh, A. K., & Almusharraf, A. (2025). Towards a sustainable retail food chain: Artificial intelligence driven dynamic pricing and promotions for food waste reduction. *Journal of Posthumanism*, 5(6), 571–588. <https://doi.org/10.63332/joph.v5i6.2073>
- Andrade, L. A. C. G., & Cunha, C. B. (2023). Disaggregated retail forecasting: A gradient boosting approach. *Applied Soft Computing*, 141, 110283. <https://doi.org/10.1016/j.asoc.2023.110283>
- Bohrium. (2026). XGBoost vs LightGBM: 2026 comparison with benchmarks [Teknik blog]. <https://www.bohrium.com/en/blog/tutorials/xgboost-vs-lightgbm/>
- Felix, P. G. (2018). Data-driven retail food waste reduction: A comparison of demand forecasting techniques and dynamic pricing strategies (Yüksek lisans tezi). University of Twente. <https://essay.utwente.nl/76380/>
- Kaggle. Food Demand Forecasting veri seti (kannanaikkal/food-demand-forecasting). <https://www.kaggle.com/datasets/kannanaikkal/food-demand-forecasting>
- Programming Insider. (2025). XGBoost vs. LightGBM (and CatBoost) for retail recommendation models: A technical benchmark [Teknik blog]. <https://programminginsider.com/xgboost-vs-lightgbm-and-catboost-for-retail-recommendation-models-a-technical-benchmark/>
- Syed, T. A., Aslam, H., Bhatti, Z. A., Mehmood, F., & Pahuja, A. (2024). Dynamic pricing for perishable goods: A data-driven digital transformation approach. *International Journal of Production Economics*, 277, 109405. <https://doi.org/10.1016/j.ijpe.2024.109405>
- UNEP. (2024). Food Waste Index Report 2024: Think eat save — Tracking progress to halve global food waste. United Nations Environment Programme.
- Wang, J., Chong, W. K., Lin, J., & Hedenstierna, C. P. T. (2023). Retail demand forecasting using spatial-temporal gradient boosting methods. *Journal of Computer Information Systems*, 64(5), 652–664. <https://doi.org/10.1080/08874417.2023.2240753>
- XGBoosting.com. (t.y.). XGBoost vs LightGBM [Teknik referans]. <https://xgboosting.com/xgboost-vs-lightgbm/>