

Gıda İsrafının Azaltılmasında Yapay Zeka

Talep Tahmini ve Dinamik İndirimleme

Osman Furkan Erkan, Nermin Kılıçarslan, Dilara Kuyar, Ahsen Nisa Sarıkaya — Concept Note & Implementation Plan

Concept Note

1. Proje Genel Bakışı (Project Overview)

Bu capstone projesi, süpermarket ve restoran gibi gıda perakendecilerinin karşılaştığı temel bir pazarlama ve operasyon sorununu ele almaktadır: hangi ürünlerin yakın vadede satılamayacağını önceden kestirilememesi. Bu belirsizlik, doğru ürüne doğru zamanda doğru indirimin uygulanamamasına yol açmakta; bu da hem gelir kaybına hem de gıda israfına neden olmaktadır. Proje, yapılandırılmış perakende satış verisiyle eğitilen makine öğrenmesi tabanlı (gradient boosting — XGBoost/LightGBM) bir talep tahmini modeli geliştirerek israf riski taşıyan ürün-şube kombinasyonlarını haftalar öncesinden tespit etmeyi ve bu tahmine dayalı, hedefli dinamik indirim önerileri üretmeyi amaçlamaktadır.

Pazarlama bağlamı şu şekilde tanımlanmaktadır: Hedef kitle hem (a) sadakat uygulaması üzerinden alışveriş yapan, fiyata duyarlı son tüketiciler hem de (b) mağaza içi fiyatlandırma ve promosyon kararlarını veren kategori/pazarlama ekipleridir. Ürün kapsamı, kısa raf ömürlü ve israf riski yüksek gıda kategorileridir. Kanal, mobil sadakat uygulaması bildirimleri ve elektronik raf etiketleri/uygulama içi “günün fırsatı” alanlarıdır. Müşteri yolculuğunda odak nokta, tekrarlayan (rutin) satın alma ve sepete ekleme kararı anıdır; burada doğru zamanlanmış bir indirim teklifi hem israfı azaltabilir hem de dönüşüm oranını artırabilir.

Projenin potansiyel etkisi iki yönlüdür. Müşteri tarafında, kişiselleştirilmiş ve doğru zamanlanmış indirim bildirimleri algılanan değeri artırarak dönüşüm oranını yükseltebilir ve sadakat uygulaması etkileşimini güçlendirebilir. İşletme tarafında ise israf kaynaklı gelir kaybının azaltılması, indirimli ürünlerde satış devri (sell-through) oranının artırılması ve düşük perakende kâr marjlarının (yaklaşık %0,2–%6,1 aralığında) israf kaynaklı kayıplara karşı korunması hedeflenmektedir. Böylece proje, ölçülebilir pazarlama değerini operasyonel sürdürülebilirlik hedefiyle bir araya getirmektedir.

2. Hedefler ve Pazarlama KPI'ları (Objectives and Marketing KPIs)

Amaçlar:

- Ürün-şube (dağıtım merkezi) düzeyinde haftalık talep tahmini üreten bir gradient boosting modeli (XGBoost ve/veya LightGBM) geliştirmek ve bu modeli basit bir baseline (naif/hareketli ortalama tahmin) ile karşılaştırmak.
- Talep tahminini kural tabanlı bir dinamik indirim öneri motoruna bağlayarak israf riski taşıyan ürünler için otomatik, mağaza düzeyinde indirim önerileri üretmek.
- Bu öneri motorunun çıktısını, sadakat uygulaması bildirim biçiminde kişiselleştirilmiş bir pazarlama aksiyonuna dönüştürecek bir kavram kanıtı (proof of concept) sunmak.

Pazarlama KPI'ları:

- Tahmin doğruluğu: MAE/RMSE ile ölçülen talep tahmini hatası (baseline'a kıyasla iyileşme yüzdesi).
- Promosyon/kampanya etkinliği: `emailer_for_promotion` ve `homepage_featured` değişkenlerinin `num_orders` üzerindeki etkisinden türetilen promosyon dönüşüm oranı.
- Satış devri (sell-through) oranı: önerilen indirimin uygulandığı ürünlerde talep-stok dengesindeki iyileşme.

- İsrif azaltım oranı (proxy metrik): düşük talepli olarak öngörülen ürünlerde, indirim sonrası gerçekleşen talep artışının israf riskini ne ölçüde azalttığı.
- Müşteri etkileşimi: sadakat uygulaması bildirimlerinin açılma/tıklama oranı (click-through rate) — kavramsal olarak tanımlanacak, gerçek uygulama entegrasyonu kapsam dışıdır.

Baseline ve hedef: Baseline olarak veri setindeki geçmiş ortalama tahmin hatası ve promosyonsuz dönemlerdeki ortalama satış devri oranı kullanılacaktır. Projenin başarı kriteri, geliştirilen modelin MAE değerinde baseline'a kıyasla anlamlı bir iyileşme sağlaması (hedef: ~%10–15 azalma) ve önerilen indirimlerin, geçmiş promosyon dönemleriyle karşılaştırıldığında benzer ya da daha yüksek bir talep artışı yaratmasıdır. Kesin sayısal hedefler, veri araştırması aşamasındaki keşifsel analiz tamamlandıkça netleştirilecektir.

3. Arka Plan ve Pazarlama Bağlamı (Background and Marketing Context)

Gıda israfı, hem çevresel hem de ticari açıdan önemli bir sorundur. Birleşmiş Milletler Çevre Programı'nın 2024 Gıda İsrafı Endeksi Raporu'na göre 2022 yılında küresel ölçekte 1,05 milyar ton gıda israf edilmiş; bunun %12'si (yaklaşık 131 milyon ton) perakende aşamasında gerçekleşmiştir. Bu pay oransal olarak küçük görünse de, mutlak miktarın büyüklüğü ve perakendecinin israfı fiyatlandırma/promosyon kararları üzerinden doğrudan etkileme gücü, sorunu pazarlama ekipleri için de önemli kılmaktadır; zira düşük perakende kâr marjları (%0,2–%6,1) israf kaynaklı kayıplara karşı özellikle hassastır. Sorundan en çok etkilenen taraflar, israf nedeniyle gelir kaybeden perakendeciler, fiyata duyarlı son tüketiciler ve dolaylı olarak sürdürülebilirlik hedefleriyle ilgilenen paydaşlardır.

Günümüzde birçok perakendeci, indirim/promosyon kararlarını geçmiş tecrübeye dayalı, büyük ölçüde manuel ve genel kurallara (örn. son kullanma tarihine belirli gün kala sabit bir indirim uygulamak) dayalı biçimde almaktadır. Bu yaklaşım, ürün-şube düzeyindeki talep farklılıklarını, mevsimselliği ve geçmiş promosyonların etkisini dikkate almadığından ya gereğinden erken/derin indirimlerle marj kaybına ya da geç kalınan indirimlerle israfa yol açabilmektedir. Literatürde de görüldüğü üzere (Felix, 2018; Abdullah vd., 2025), talep tahminiyle dinamik fiyatlandırmayı birlikte ele alan yaklaşımlar, yalnızca tahmin doğruluğunu artırmaktan daha fazla israf azaltımı sağlamaktadır; bu da mevcut manuel/kural tabanlı uygulamaların önemli bir sınırlılığına işaret etmektedir.

Bu noktada yapay zeka tabanlı bir yaklaşım belirgin bir değer sunmaktadır: gradient boosting tabanlı modeller (XGBoost/LightGBM), yapılandırılmış perakende verisinde yüksek doğruluk ve yorumlanabilirlik sağlayarak (Andrade & Cunha, 2023; Abdullah vd., 2025) her ürün-şube kombinasyonu için ayrıştırılmış, mevsimsellik ve geçmiş promosyonlardan etkilenen bir talep tahmini üretebilmektedir. Bu sayede pazarlama ve kategori ekipleri, genel kurallar yerine veriye dayalı, ürün ve şube bazında farklılaştırılmış indirim kararları alabilir. Literatür taramasında da belirlenen boşluk — mevcut çalışmaların çoğunlukla operasyonel metriklerle (israf miktarı, kâr marjı) odaklanıp müşteri tarafındaki pazarlama sonuçlarını (dönüşüm, sadakat etkileşimi, elde tutma) sistematik olarak ele almaması — bu projenin doğrudan yanıtladığı fırsat alanıdır.

4. Önerilen Yapay Zeka Metodolojisi

Projede kullanılacak yapay zeka yaklaşımı, ürün ve şube bazında talebi tahmin eden makine öğrenmesi modelleri ile bu tahminleri kullanarak israf riski taşıyan ürünler için indirim kararları üreten dinamik bir fiyatlandırma motorunun entegrasyonuna dayanmaktadır. Bu yaklaşım, hangi ürünlerin yakın vadede satılamayacağını önceden belirleyip doğru zamanlanmış indirim teklifleri sunarak hedeflenen fiyata duyarlı müşteri segmentinde dönüşüm oranını artırma ve israfı azaltma pazarlama hedefine doğrudan hizmet etmektedir. Uygulamada temel algoritmalar olarak yapılandırılmış (tablo) perakende verisinde yüksek performans gösteren gradient boosting tabanlı XGBoost ve LightGBM modelleri kullanılacaktır. Bu modellerin seçilmesinin nedeni, derin öğrenme (örn. LSTM) yöntemlerine kıyasla yaklaşık 456 bin satırlık orta ölçekli veri setlerinde daha hızlı eğitim süresi sunmaları, daha az hesaplama kaynağı gerektirmeleri ve SHAP değerleri gibi araçlarla

pazarlama ekipleri için yüksek yorumlanabilirlik sağlamalarıdır. Geliştirilecek çözüm, teknik açıdan RMSE (Kök Ortalama Kare Hata) ve MAE (Ortalama Mutlak Hata) metrikleri kullanılarak değerlendirilirken; pazarlama ve iş kriterleri açısından indirim bildirimine tepki oranı, dönüşüm oranı, ürün geri kazanım (sell-through) oranı, müşteri etkileşimi ve elde tutma (retention) gibi metriklerle ölçülecektir. Çözümün başarısı, yapay zeka destekli dinamik fiyatlandırmanın uygulanmadığı geçmiş satış verilerinden elde edilecek temel bir ölçümle (baseline) karşılaştırılarak doğrulanacaktır.

5. Mimari / İş Akışı Tasarım Şeması

Önerilen çözümün girdiden başlayıp hedeflenen pazarlama eylemine ve KPI ölçümüne kadar nasıl ilerlediğini gösteren uçtan uca iş akışı aşağıda özetlenmiştir:

İş Akışı Şeması:

[Veri Kaynağı] → [Ön İşleme / Özellik Hazırlığı] → [Yapay Zeka Modeli (Talep Tahmini)] → [Çıktı / İndirim Önerisi Motoru] → [İnsan İncelemesi (Yönetici Onayı)] → [Pazarlama Eylemi / Kanalı] → [KPI Ölçümü ve Kapalı Döngü]

Bileşenlerin Rollerini:

- **Veri Kaynağı:** Yemek teslimat platformuna (veya entegre edilecek süpermarkete) ait haftalık sipariş, ürün, şube/dağıtım merkezi bilgileri ile ödeme ve taban fiyatlarını (checkout_price, base_price) içeren yapılandırılmış (CSV) işlemsel veri setidir.
- **Ön İşleme / Özellik Hazırlığı:** Üç farklı veri tablosunun birleştirildiği, checkout_price ile base_price arasındaki farktan geçmiş indirim oranlarının hesaplandığı ve mevsimsellik/promosyon özelliklerinin (emailer_for_promotion vb.) modele uygun hale getirildiği veri mühendisliği aşamasıdır.
- **Yapay Zeka Modeli:** Her bir ürün ve şube kombinasyonu için haftalık talep miktarını öngören XGBoost veya LightGBM tabanlı tahmine dayalı makine öğrenmesi modelidir.
- **Çıktı / İndirim Önerisi Motoru:** Modelin tahminlerine dayanarak israf riski taşıyan (talebi düşük beklenen) ürünler için haftalık bir "risk listesi" oluşturur ve geçmiş fiyat esnekliği verilerini kullanarak bu israfı ertecek optimal indirim oranını hesaplayıp bir karar önerisi sunar.
- **İnsan İncelemesi (Yönetici Onayı):** Aşırı otomasyonun "her zaman indirimde" algısı yaratarak marka fiyatlandırma stratejisine zarar vermesini önlemek amacıyla, üretilen kişiselleştirilmiş indirim önerileri kategori veya pazarlama yöneticisinin incelemesine ve onayına sunulur. Bu aşamada kararların güvenilirliği SHAP değerleriyle desteklenir.
- **Pazarlama Eylemi / Kanalı:** Onaylanan indirimler, fiyata duyarlı sadakat müşterilerine mobil uygulama üzerinden hedefli anlık bildirimler (push notification) olarak iletilir ve mağaza içi elektronik raf etiketlerindeki "günün fırsatı" alanlarında güncellenir.
- **KPI Ölçümü ve Kapalı Döngü:** İndirim bildirimi sonrasında müşterinin tepki oranı, dönüşüm (sepete ekleme) oranı ve ürün geri kazanım (israf azaltım) miktarı ölçülür. Elde edilen sonuçlar temel bir ölçümle (baseline) karşılaştırılır ve modelin sonraki haftalarda daha iyi performans göstermesi için geri bildirim (retraining) olarak sisteme beslenir.

6. Veri Kaynakları

Projede kullanılacak temel veri kaynağı, Kaggle platformunda kamuya açık olarak sunulan ve gerçek bir yemek teslimat şirketinin anonimleştirilmiş operasyonel kayıtlarına dayanan "Food Demand Forecasting" veri setidir (CSV formatında). Yaklaşık 456 bin işlem kaydı içeren ve 145 haftalık bir dönemi kapsayan bu veri seti; haftalık talep (num_orders), dağıtım merkezi kimliği (center_id), ürün kimliği (meal_id), ödeme fiyatı (checkout_price), taban fiyat (base_price) ve promosyon durumu (emailer_for_promotion, homepage_featured) gibi değişkenleri birbiriyle ilişkili üç tablo halinde barındırmaktadır. Bu veriler, geçmiş indirim oranlarının hesaplanmasına ve fiyat esnekliğinin modellenmesine olanak tanıdığı için mağaza düzeyinde kişiselleştirilmiş indirim önerileri üretme pazarlama problemiyle doğrudan ilgilidir. Veri ön işleme adımları, eksik değer içermeyen bu üç tablonun birleştirilmesini ve checkout_price ile base_price arasındaki fark üzerinden geçmişte uygulanan indirim oranlarının türetilmesini kapsayacaktır. Veri seti toplulaştırılmış işlem düzeyinde olup bireysel müşteri kimliği içermediğinden KVKK/GDPR kapsamında kişisel veri işleme riski düşüktür; ancak projenin gerçek bir sadakat uygulamasıyla genişletilmesi durumunda açık rıza, anonimleştirme ve veri minimizasyonu ilkelerinin uygulanması gerekliliği dikkate alınmıştır.

7. Literatür ve Endüstri İncelemesi (Literature and Industry Review)

Konuyla ilgili literatür, üç tematik ekseninde toplanmaktadır: (1) perakende talep tahmininde makine öğrenmesi yaklaşımları, (2) gıda israfına özgü dinamik fiyatlandırma ve promosyon çalışmaları ve (3) gradient boosting yöntemlerinin (XGBoost/LightGBM) tablo verisi üzerindeki karşılaştırmalı performansı. Andrade ve Cunha (2023) ile Wang vd. (2023), büyük ölçekli ve dağıtık perakende talep tahmininde gradient boosting tabanlı yaklaşımların geleneksel istatistiksel yöntemlere kıyasla daha iyi ölçeklenebilirlik ve doğruluk sağladığını göstermiştir; buna karşın bazı sebze/meyve senaryolarında LSTM ve destek vektör regresyonunun (SVR) daha iyi sonuç verebildiği de bildirilmiştir, bu da model seçiminin ürün kategorisine göre değişebileceğine işaret etmektedir. Gıda israfına özgü alanda Felix (2018), talep tahmini ile

dinamik fiyatlandırmanın birlikte ele alınmasının tek başına daha iyi tahminden daha fazla israf azaltımı sağladığını ortaya koymuş; Abdullah, Shaikh ve Almusharraf (2025) ise Gradient Boosting'in SVR, Karar Ağacı, KNN, Rastgele Orman ve Yapay Sinir Ağları'na kıyasla en düşük hata oranı ve en yüksek R^2 değerini sunduğunu bulmuştur. Syed vd. (2024), düşük perakende kâr marjlarının (%0,2–%6,1) israf kaynaklı kayıplara karşı özellikle hassas olduğunu vurgulayarak yapay zeka destekli dinamik fiyatlandırmanın hem israfı azaltma hem kârlılığı artırma potansiyeline dikkat çekmiştir. Algoritmaların temelini oluşturan literatür incelendiğinde (Chen & Guestrin, 2016; Ke vd., 2017), LightGBM'in yaprak-bazlı büyüme ve histogram tabanlı bölme sayesinde büyük veri setlerinde daha hızlı eğitim süresi sunduğu, XGBoost'un ise seviye-bazlı büyümesi nedeniyle aşırı öğrenmeye karşı daha kararlı olduğu ve SHAP gibi araçlarla daha açıklanabilir sonuçlar verdiği görülmektedir. Mevcut literatürün büyük kısmı tahmin/fiyatlandırma performansını yalnızca operasyonel metriklerle (israf miktarı, kâr marjı) değerlendirmekte; indirim bildirimine tepki oranı, sadakat uygulaması etkileşimi veya tekrar satın alma gibi pazarlama tarafındaki sonuçları sistematik olarak ele almamaktadır. Bu proje, model çıktısını ölçülebilir bir pazarlama aksiyonuna (hedefli indirim bildirimi) dönüştürerek ve bu aksiyonun hem israf azaltımı hem de müşteri davranışı KPI'ları üzerindeki etkisini değerlendirerek tam olarak bu boşluğu doldurmayı hedeflemektedir.

Implementation Plan

1. Teknoloji Yığını (Technology Stack)

Bölüm 5'te belirtilen uçtan uca mimari iş akışını hayata geçirmek için sürece özgü, sektör standartlarında en çok tercih edilen aşağıdaki teknoloji ve araçlar kullanılacaktır:

- **Dil, Ortam ve Sürüm Kontrolü (Veri Kaynağı → Özellik Hazırlığı Aşamaları):**
 - **Programlama Dili:** Projenin ana dili olarak **Python** kullanılacaktır. Python, makine öğrenmesi kütüphaneleri (XGBoost, LightGBM) ile kusursuz uyumu ve veri ön işleme süreçlerindeki esnekliği nedeniyle bu tür projelerde tartışmasız sektör standardıdır.
 - **Geliştirme Ortamları (IDE ve Prototipleme):**
 - **Prototipleme ve EDA (Keşifsel Veri Analizi):** Verilerin ilk incelenmesi, modelleme denemeleri ve görselleştirmeler için etkileşimli bir ortam sunan **Google Colab** (bulut tabanlı) veya yerel **Jupyter Notebook** kullanılacaktır.
 - **Uçtan Uca Geliştirme (Production & Scripting):** Projenin modüler hale getirilmesi, Streamlit kontrol panelinin yazılması ve son haline getirilmesi için pazarın en popüler ve hafif kod editörlerinden olan **Visual Studio Code (VS Code)** tercih edilecektir.
 - **Sürüm Kontrolü ve Çevre Yönetimi:** Teslim yönergelerine uygun olarak projenin yedeklenmesi ve versiyonlanması için **Git/GitHub**; paket ve bağımlılık yönetimi için ise proje izolasyonu sağlayan **Conda** veya Python **venv** kullanılacaktır.
 - **Veri Analitiği Kütüphaneleri:** CSV dosyalarının okunması, tabloların birleştirilmesi ve taban/ödeme fiyatı üzerinden geçmiş indirim oranı gibi özellikleri üretmek için **Pandas** ve **NumPy** kullanılacaktır.
- **Model Geliştirme (Yapay Zeka Modeli Aşaması):**
 - **Algoritmalar:** Orta ölçekli (yaklaşık 456 bin satırlık) yapılandırılmış tablo verisinde yüksek doğruluk ve eğitim hızı sağlayan **XGBoost** ve **LightGBM** kütüphaneleri kullanılacaktır.
 - **Değerlendirme:** Tahmin başarılarını (RMSE, MAE) ölçmek için **Scikit-learn** kütüphanesinden yararlanılacaktır.
- **Açıklanabilirlik ve Yönetici Paneli (Çıktı → İnsan İncelemesi Aşamaları):**
 - **Model Açıklanabilirliği:** Pazarlama yöneticilerinin, modelin indirim önerisine neden ulaştığını anlayıp güvenle onay verebilmesi (kutu-siyah problemini aşmak) için **SHAP (SHapley Additive exPlanations)** değerleri kullanılacaktır.
 - **Kontrol Paneli (Dashboard):** Risk listelerinin ve önerilen indirimlerin görselleştirilip onaylanabilmesi amacıyla **Streamlit** (Python tabanlı hızlı web uygulaması aracı) kullanılarak basit bir karar destek arayüzü tasarlanacaktır. (Bu, projenin "insan gözetimi" şartını teknik olarak karşılayacaktır).
- **Pazarlama Entegrasyonu (Pazarlama Eylemi → KPI Aşamaları):**
 - Üretilen onaylı indirim kararlarını mobil sadakat uygulaması ve elektronik raf etiketleri kanalına aktarmak üzere, sistemin çıktıları bir CRM platformunun (örneğin HubSpot, Salesforce veya özel bir iç sistem) okuyabileceği formatlarda (API JSON çıktısı simülasyonu veya yapılandırılmış dış

aktarım dosyaları) yapılandırılacaktır. Pazarlama KPI'larının (dönüşüm oranı vb.) analizi yine Python (**Matplotlib/Seaborn** vb.) kullanılarak görselleştirilecektir.

2. Zaman Çizelgesi ve Görev Dağılımı (Timeline and Task Distribution)

Kavram notunun teslim tarihi olan 30 Ağustos 2026'nın ardından, uygulamanın kalan aşamaları için aşağıdaki 8 haftalık zaman çizelgesi öngörülmüştür. Çizelge, veri hazırlığından final demo ve dokümantasyona kadar projenin tüm kritik aşamalarını kapsamaktadır.

Aşama	Süre	Ana Faaliyetler	Çıktı
1. Veri Hazırlama & Ön İşleme	Hafta 1 (1–7 Eyl)	Kaggle veri setinin (talep, dağıtım merkezi, ürün-fiyat tabloları) birleştirilmesi; eksik/aykırı değer kontrolü; indirim oranı ($\text{checkout_price}/\text{base_price}$) ve mevsimsellik özelliklerinin türetilmesi.	Temiz, birleştirilmiş veri seti
2. Baseline & Model Geliştirme	Hafta 2–3 (8–21 Eyl)	Naif/hareketli ortalama baseline kurulumu; XGBoost ve LightGBM modellerinin eğitilmesi; hiperparametre ayarı.	Çalışan talep tahmini modeli (v1)
3. Test, Doğrulama & Karşılaştırma	Hafta 4 (22–28 Eyl)	MAE/RMSE ile model karşılaştırması; baseline'a karşı iyileşme yüzdesinin hesaplanması; SHAP ile açıklanabilirlik analizi.	Model karşılaştırma raporu
4. İndirim Motoru & Entegrasyon	Hafta 5–6 (29 Eyl–12 Eki)	Tahmine dayalı dinamik indirim kural setinin kodlanması; sadakat uygulaması bildirimi/raf etiketi senaryosu için kavramsal arayüz tasarımı.	Uçtan uca prototip (tahmin → indirim önerisi)
5. KPI Değerlendirme	Hafta 7 (13–19 Eki)	Teknik metriklerin yanı sıra promosyon etkinliği, satış devri ve israf azaltım proxy metriklerinin hesaplanması.	KPI değerlendirme özeti
6. Final Demo, Dokümantasyon & Sunum	Hafta 8 (20–26 Eki)	Demo hazırlığı, GitHub deposunun düzenlenmesi, final raporun ve sunumun tamamlanması.	Final demo + rapor + sunum

Not: Tarihler gerçekçi bir planlama sağlamak amacıyla haftalık bloklar hâlinde belirtilmiştir; ekip içi ilerleme durumuna göre ±birkaç gün esneklik uygulanabilir.

Ekip, dört üyeden oluşmaktadır ve görevler, herkesin literatür/veri/teknoloji incelemesindeki katkılarıyla uyumlu şekilde dağıtılmıştır. Aşağıdaki matris, her üyenin ana sorumluluk alanını ve ilgili olduğu aşamaları göstermektedir.

Ekip Üyesi	Ana Sorumluluk Alanı	İlgili Aşama(lar)
Osman Furkan Erkan	Model geliştirme: XGBoost/LightGBM eğitimi, hiperparametre optimizasyonu, teknik değerlendirme (MAE/RMSE, SHAP).	Aşama 2, 3
Nermin Kılıçarslan	Proje çerçevesi ve pazarlama tarafı: kavram notu (genel bakış, hedefler/KPI, arka plan), zaman çizelgesi/görev dağılımı, kilometre taşları ve teslimatların koordinasyonu.	Tüm aşamalar (koordinasyon), Aşama 5

Ekip Üyesi	Ana Sorumluluk Alanı	İlgili Aşama(lar)
Dilara Kuyar	Veri mühendisliği: veri setinin birleştirilmesi, temizlenmesi, özellik mühendisliği (indirim oranı, mevsimsellik).	Aşama 1, 2
Ahsen Nisa Sarıkaya	Dinamik indirim motoru ve entegrasyon tasarımı; final demo ve dokümantasyon hazırlığı.	Aşama 4, 6

3. Kilometre Taşları ve Teslimatlar (Milestones and Deliverables)

Projenin somut ilerlemesini göstermek amacıyla aşağıdaki kilometre taşları belirlenmiştir. Her kilometre taşı, zaman çizelgesindeki ilgili aşamanın sonunda ölçülebilir bir çıktıyla ilişkilendirilmiştir.

Kilometre Taşı	Hedef Tarih	Tamamlanma Kanıtı / Beklenen Çıktı
M1 — Veri Hazır	7 Eylül 2026	Üç Kaggle tablosu (talep, dağıtım merkezi, ürün-fiyat) birleştirilmiş, eksik/aykırı değer kontrolü yapılmış, indirim oranı ve mevsimsellik özellikleri türetilmiş tek bir veri seti.
M2 — Baseline Kurulu	14 Eylül 2026	Naif/hareketli ortalama tahmin baseline'ı çalışır durumda; MAE/RMSE referans değerleri hesaplanmış.
M3 — İlk Çalışan Prototip	21 Eylül 2026	XGBoost ve LightGBM modellerinin ilk sürümleri eğitilmiş ve baseline ile karşılaştırılabilir durumda.
M4 — Model Doğrulandı	28 Eylül 2026	Model çıktıları SHAP ile açıklanmış; en iyi performans gösteren model (XGBoost/LightGBM) seçilmiş ve hedef MAE iyileştirmesine ulaşılmış.
M5 — Uçtan Uca Prototip Entegre	12 Ekim 2026	Talep tahmini çıktısı, dinamik indirim öneri motoruna bağlanmış; örnek ürün-şube senaryoları için indirim önerileri üretilebiliyor.
M6 — KPI Değerlendirmesi Tamamlandı	19 Ekim 2026	Promosyon etkinliği, satış devri ve israf azaltım proxy metrikleri hesaplanmış; bulgular pazarlama KPI'larıyla ilişkilendirilmiş.
M7 — Final Demo & Teslim	26 Ekim 2026	Çalışan demo, final rapor, sunum dosyası ve güncellenmiş GitHub deposu teslim hazır.

4. Zorluklar ve Azaltım Stratejileri (Challenges and Mitigation Strategies)

Projenin beklendiği gibi ilerlemesini engelleyebilecek başlıca riskler ve bunlara yönelik azaltım stratejileri aşağıda özetlenmiştir:

- Veri kalitesi ve seyreklik:** Bazı ürün-şube kombinasyonlarının talebi düşük/seyrekle olabilir, bu da tahmin belirsizliğini artırır. Azaltım: düşük hacimli SKU'lar için ayrı bir değerlendirme eşiği tanımlanacak, gerekirse bu kombinasyonlar toplulaştırılmış (aggregate) düzeyde modelleneyecektir.
- Küçük/dengesiz veri ve zamansal kapsam sınırlılığı:** Veri seti 145 haftayla sınırlıdır; çok yıllık mevsimsellik veya nadir talep şokları (tatiller, krizler) yeterince temsil edilmeyebilir. Azaltım: model performansı farklı zaman dilimlerinde çapraz doğrulama (time-series cross-validation) ile test edilecek, sonuçların sınırlılığı final raporda açıkça belirtilecektir.
- Model çıktı kalitesi ve aşırı öğrenme (overfitting):** Gradient boosting modelleri, özellikle az örnekli ürün-şube kombinasyonlarında eğitim verisine aşırı uyum sağlayabilir. Azaltım: düzenlileştirme (regularization) parametreleri, erken durdurma (early stopping) ve baseline ile karşılaştırmalı doğrulama kullanılacaktır.
- Önyargı (bias) riski:** Geçmiş promosyon verisi belirli ürün/şube kombinasyonlarında yetersiz temsil edilmişse, model bu kombinasyonlar için güvenilir olmayan tahminler üretip adaletsiz indirim dağılımına yol açabilir. Azaltım: şube ve kategori bazında tahmin hatası izlenecek, sapmalar tespit edilirse ilgili kombinasyonlar için insan onayı zorunlu kılınacaktır.

- Gizlilik: Kullanılan Kaggle veri seti anonimleştirilmiş ve toplulaştırılmış olup bireysel müşteri kimliği içermemektedir; bu nedenle proje kapsamında düşük gizlilik riski taşımaktadır. Azaltım: proje ileride gerçek sadakat uygulaması verisiyle genişletilirse, açık rıza, anonimleştirme ve veri minimizasyonu ilkeleri uygulanacaktır.
- Marka güvenliği ve aşırı otomasyon: Tamamen otomatik indirim kararları, "her zaman indirimde" algısı yaratarak marka fiyat algısını olumsuz etkileyebilir. Azaltım: önerilen indirimler kategori yöneticisi onayından geçecek şekilde insan gözetimli (human-in-the-loop) bir iş akışı benimsenecektir.
- API/platform kısıtlamaları ve üçüncü taraf bağımlılığı: Kullanılan veri seti belirli bir yemek teslimat platformuna aittir; gerçek bir süpermarket zincirine uygulanmadan önce modelin yeniden kalibre edilmesi gerekir. Azaltım: bulgular temkinli biçimde yorumlanacak, proje kapsamı bir kavram kanıtı (proof of concept) olarak sınırlandırılacaktır.
- Maliyet ve gecikme (latency): Haftalık yeniden eğitim döngüsü hesaplama kaynağı gerektirebilir. Azaltım: LightGBM'in hız avantajından yararlanılacak, model eğitimi haftalık toplu (batch) işlem olarak tasarlanıp gerçek zamanlı tahmin gerektirmeyecektir.
- Gerçek pazarlama etkisini ölçme zorluğu: Veri setinde gerçek müşteri düzeyinde dönüşüm/tıklama verisi bulunmadığından, pazarlama KPI'larının bir kısmı (örn. bildirim tıklama oranı) yalnızca kavramsal/proxy düzeyde tanımlanabilecektir. Azaltım: bu sınırlılık raporda açıkça belirtilecek, ölçülebilir proxy metrikler (satış devri oranı, promosyon dönüşüm oranı) önceliklendirilecektir.

Kritik bileşenler için basit yedek (fallback) seçenekleri de planlanmıştır: XGBoost/LightGBM modelinin beklenen performansı sağlayamaması durumunda, naif/hareketli ortalama baseline üzerine kural tabanlı basit bir indirim mantığı (örn. son kullanma tarihine kalan gün sayısına göre kademeli indirim) devreye alınabilir; bu, projenin uçtan uca çalışır bir prototip sunmasını garanti altına alır.

5. Etik ve Sorumlu Yapay Zeka Değerlendirmeleri (Ethical and Responsible AI Considerations)

Proje kapsamında kullanılan veri seti (Kaggle "Food Demand Forecasting") anonimleştirilmiş, toplulaştırılmış işlem düzeyinde olup bireysel müşteri kimliği içermemektedir; bu nedenle mevcut aşamada KVKK/GDPR anlamında kişisel veri işleme riski düşüktür. Bununla birlikte, projenin nihai vizyonu olan kişiselleştirilmiş indirim bildirimleri, gerçek bir sadakat uygulaması müşteri verisiyle entegre edilmeyi gerektirmektedir; bu noktada açık rıza (consent), veri minimizasyonu ve anonimleştirme ilkelerinin uygulanması, ayrıca müşterilerin kendi verilerinin nasıl kullanıldığını bilme ve itiraz etme hakkının korunması esastır.

Adillik ve önyargı (fairness/bias) açısından, geçmiş promosyon verisinin bazı ürün/şube kombinasyonlarında dengesiz dağılmış olması, modelin belirli mağazalar veya müşteri segmentleri için sistematik olarak farklı (adaletsiz) indirim önerileri üretmesine yol açabilir. Bu riski azaltmak için, model çıktıları şube ve kategori bazında düzenli olarak izlenecek ve önemli sapmalar tespit edildiğinde model yeniden kalibre edilecektir.

Şeffaflık ve açıklanabilirlik (explainability) açısından, önerilen indirim kararlarının pazarlama ve kategori ekipleri tarafından güvenilir bulunması için model çıktılarının SHAP gibi araçlarla yorumlanabilir kılınması planlanmaktadır; bu sayede "neden bu ürüne bu indirim önerildi" sorusuna somut bir yanıt verilebilecektir.

Manipülasyon riski ve marka güvenliği bağlamında, tamamen otomatik ve sık tekrarlanan indirim bildirimleri müşteride yapay bir aciliyet hissi yaratarak manipülatif bir pazarlama pratiğine dönüşebilir ya da markanın fiyat istikrarı algısını zedeleyebilir. Bu nedenle bildirim sıklığı ve içeriği için makul üst sınırlar tanımlanacak ve indirim mesajları yanıltıcı olmayacak, gerçek ve doğrulanabilir fiyat bilgisine dayanacak şekilde tasarlanacaktır.

İnsan gözetimi (human oversight) açısından, modelin ürettiği indirim önerileri doğrudan otomatik olarak uygulanmayacak; kategori/pazarlama ekibinin onayından geçecek bir insan-döngüde (human-in-the-loop) iş akışı benimsenecektir. Bu, hem hatalı/önyargılı önerilerin filtrelenmesini hem de nihai kararın sorumluluğunun insanda kalmasını sağlar.

Bu belgenin hazırlanmasında yapay zeka (AI) destekli araçlardan yararlanılmıştır; içerik, ekip üyeleri tarafından önceki Literatür Taraması, Veri Araştırması ve Teknoloji İncelemesi bulgularına dayanılarak gözden geçirilmiş ve doğrulanmıştır.

Abdullah, N., Shaikh, A. K., & Almusharraf, A. (2025). Towards a sustainable retail food chain: Artificial intelligence driven dynamic pricing and promotions for food waste reduction. *Journal of Posthumanism*, 5(6), 571–588. <https://doi.org/10.63332/joph.v5i6.2073>

- Andrade, L. A. C. G., & Cunha, C. B. (2023). Disaggregated retail forecasting: A gradient boosting approach. *Applied Soft Computing*, 141, 110283. <https://doi.org/10.1016/j.asoc.2023.110283>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Felix, P. G. (2018). *Data-driven retail food waste reduction: A comparison of demand forecasting techniques and dynamic pricing strategies* (Yüksek lisans tezi). University of Twente. <https://essay.utwente.nl/76380/>
- Kannanaikkal, E. U. (2018). *Food demand forecasting* [Veri seti].
- Kaggle. <https://www.kaggle.com/datasets/kannanaikkal/food-demand-forecasting>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- Syed, T. A., Aslam, H., Bhatti, Z. A., Mehmood, F., & Pahuja, A. (2024). Dynamic pricing for perishable goods: A data-driven digital transformation approach. *International Journal of Production Economics*, 277, 109405. <https://doi.org/10.1016/j.ijpe.2024.109405>
- UNEP. (2024). *Food Waste Index Report 2024: Think eat save — Tracking progress to halve global food waste*. United Nations Environment Programme.
- Wang, J., Chong, W. K., Lin, J., & Hedenstierna, C. P. T. (2023). Retail demand forecasting using spatial-temporal gradient boosting methods. *Journal of Computer Information Systems*, 64(5), 652–664. <https://doi.org/10.1080/08874417.2023.2240753>