

Machine Learning Project Documentation

AI for Food Waste Reduction — Talep Tahmini ve Dinamik İndirimleme

SIC AI 17 Capstone — Grup 11

Bu belgedeki tüm deneyler Kaggle 'Food Demand Forecasting' veri seti üzerinde bu oturumda gerçekten çalıştırılmış ve doğrulanmıştır.

Model Refinement

1. Overview


Bu bölüm, projenin Faz 3 baseline modelinin (LightGBM, tek nokta tahmini) üzerine gerçekten yeni iyileştirme denemeleri yapılan bir refinement çalışmasını belgelemektedir. Önce Faz 3-4'ün orijinal sonuçları aynı veri ve kod üzerinde yeniden üretilerek doğrulanmış; ardından (a) sızıntısız bir hiperparametre araması ve (b) quantile bandının coverage kalibrasyonu olmak üzere iki bağımsız iyileştirme denemesi çalıştırılmış ve sonuçlar gerçek (daha önce hiç görülmemiş) test seti üzerinde ölçülmüştür.

2. Model Evaluation

Baseline modelin bu oturumda yeniden eğitilmesiyle elde edilen sonuçlar, önceki raporla birebir örtüşmüştür — bu da hem veri işleme hem de model kurulumunun tutarlı ve tekrarlanabilir olduğunu doğrulamaktadır:


Metrik	Değer	Not
RMSLE (test)	0.4763	594. iterasyonda early stopping
MAE (test)	62.12 sipariş	—
Train RMSE / Valid RMSE	0.4363 / 0.4763	Aşırı öğrenme yok

Tablo 1 — Baseline modelin bu oturumda yeniden üretilen (doğrulanmış) test performansı.



Şekil 1 — Baseline model residual dağılımı (Faz 3'ten, doğrulandı).

Feature importance analizinde geçmiş talebe dayalı değişkenlerin (num_orders_roll_mean_4, num_orders_lag_1) baskın olduğu bir kez daha doğrulanmıştır; bu, aşağıdaki refinement denemelerinde feature setinin sabit tutulmasının gerekçesini oluşturmaktadır.



Şekil 2 — LightGBM feature importance (gain), doğrulanmış.

3. Refinement Techniques

Bu fazda iki somut, ölçülebilir iyileştirme denemesi gerçekten çalıştırılmıştır (kod: notebooks/refine_01_hpo.py, refine_02_final_eval.py, refine_03_quantile_calibration.py, refine_04_final_calibration.py):

- Deneme 1 — Sızıntısız hiperparametre araması: Optuna (TPE sampler) ile 40 deneme çalıştırılmış; test setine (hafta 136–145) hiç dokunulmadan, train setinin kendi içinde ayrı bir iç-validasyon penceresi (hafta 126–135) kullanılmıştır.
- Deneme 2 — Quantile band coverage kalibrasyonu: Orijinal $\alpha=0.10/0.90$ bandının test setinde %75.99 coverage verdiği doğrulanmış; ardından $\alpha=0.05/0.95$ (geniş) ve son olarak $\alpha=0.08/0.92$ (ince ayarlı) bantlar denenerek hedef %80 coverage'a yakınsanmıştır.

Her iki deneme de mevcut LightGBM altyapısını korumuş, farklı bir algoritma denenmemiştir; bu, Faz 1'deki teknoloji karşılaştırmasının (XGBoost/LightGBM/LSTM) sonucuyla ve projenin veri ölçeğiyle (~456K satır, yapılandırılmış veri) tutarlıdır.

4. Hyperparameter Tuning

Optuna araması, learning_rate, num_leaves, min_data_in_leaf, feature_fraction, bagging_fraction, bagging_freq, lambda_l1 ve lambda_l2 üzerinde 40 deneme ile yürütülmüştür. Sızıntıyı önlemek için gerçek test setine hiç dokunulmamış, bunun yerine train setinin ilk 110 haftası iç-train, sonraki 10 haftası (126–135) iç-validasyon olarak kullanılmıştır:

```
inner_train = df[df.week <= 125]      # HPO için
inner_valid = df[(df.week > 125) & (df.week <= 135)]
# gerçek test (hafta > 135) HPO sırasında HİCBİR şekilde kullanılmadı


study = optuna.create_study(direction='minimize',
                             sampler=optuna.samplers.TPESampler(seed=42))
study.optimize(objective, n_trials=40)
```

Sonuç: iç-validasyonda baseline parametreleri RMSE 0.47135 verirken, Optuna'nın bulduğu en iyi parametreler RMSE 0.46762'ye inmiştir (~%0.8 iyileşme). Bulunan en iyi parametreler ardından train setinin tamamı (hafta ≤135) ile yeniden eğitilip, daha önce hiç görülmemiş gerçek test setinde (hafta 136–145) değerlendirilmiştir:

Metrik	Baseline (orijinal)	Tuned (Optuna)	İyileşme
RMSLE (test)	0.47628	0.47534	%0.20

MAE (test)	62.12	61.80	%0.50
Best iteration	594	1360	—

Tablo 2 — Optuna ile bulunan parametrelerin gerçek, hiç görülmemiş test setindeki sonucu (koyu renkli satır: sonuç).



Şekil 3 — Baseline ve Optuna ile ayarlanmış modelin test seti karşılaştırması.

İyileşme oranı mütevazıdır (RMSLE'de %0.20, MAE'de %0.50) — bu, baseline'ın Faz 3'te zaten early-stopping ile makul bir konfigürasyona ulaştığını, dolayısıyla saf hiperparametre aramasının getirisinin sınırlı olduğunu göstermektedir. Buna karşın tuned model, daha düşük bir learning_rate (0.027 vs 0.05) ve daha fazla ağaç (1360 vs 594) ile daha kademeli/dengeli bir öğrenme eğrisi izlemiştir; bu, gürültüye karşı biraz daha dayanıklı bir model anlamına gelmektedir.

Parametre	Baseline	Tuned (Optuna)
learning_rate	0.05	0.0269
num_leaves	63	64
min_data_in_leaf	30	48
feature_fraction	0.9	0.708
bagging_fraction	0.9	0.845
bagging_freq	1	4
lambda_l1 / lambda_l2	0 / 0	0.0192 / ~0.00006

Tablo 3 — Optuna'nın bulduğu en iyi hiperparametre kombinasyonu.

5. Cross-Validation

Refinement denemeleri sırasında iki farklı doğrulama katmanı bilinçli olarak ayrılmıştır: (1) hiperparametre araması sırasında kullanılan iç-validasyon (hafta 126–135) ve (2) nihai, tarafsız değerlendirme için hiç dokunulmayan gerçek test seti (hafta 136–145). Bu ayırım, HPO sürecinin test metriğine dolaylı olarak sızıp iyimser bir sonuç üretmesini engellemek için özellikle kurulmuştur — yaygın bir hata olan 'test setinde arama yapıp yine test setinde raporlama' tuzağından kaçınılmıştır.

Standart k-fold yine kullanılmamıştır (gerekçe önceki fazda açıklandığı gibi panel/zaman serisi veri sızıntısı riskidir). Walk-forward cross-validation, zaman ve hesaplama kısıtları nedeniyle bu refinement turunda uygulanmamış olup bir sonraki iyileştirme adımı olarak önerilmektedir.

6. Feature Selection

Bu refinement turunda feature seti kasıtlı olarak sabit tutulmuştur; amaç, iyileştirmenin etkisini yalnızca (a) hiperparametreler ve (b) quantile kalibrasyonu değişkenlerine atfedebilmektir. Feature importance sonuçları (Şekil 2), önceki fazdaki bulguları doğrulamış ve mevcut 18 feature'lık setin korunmasını desteklemiştir. Feature çıkarma/genişletme denemeleri, ileriki bir iterasyon için önerilen bir sonraki adım olarak not edilmiştir (örn. haftalık fiyat değişim hızı veya center bazlı geçmiş talep varyansı gibi yeni feature'lar).

Test Submission

1. Overview

Bu bölüm, refinement denemelerinin (hiperparametre ayarı ve quantile kalibrasyonu) gerçek test setine nasıl uygulandığını ve sonuçların nasıl ölçüldüğünü belgeler. Kaggle'ın orijinal test.csv dosyası hedef değişkeni içermediğinden, önceki fazda olduğu gibi zaman bazlı ayrılan son 10 hafta (136–145) etiketli test seti olarak kullanılmıştır; bu, hem baseline hem de yeni denemeler için aynı, tutarlı zemin sağlamıştır.

2. Data Preparation for Testing

Test verisi, Faz 1–2 pipeline'ı bu oturumda uçtan uca yeniden çalıştırılarak üretilmiştir (train.csv + meal_info.csv + fulfilment_center_info.csv birleştirme, discount_ratio, lag/rolling feature'lar, sin/cos mevsimsellik, LabelEncoder). Üretilen veri seti boyutu (456.548 satır, 26 kolon; train 423.727 / test 32.821) önceki raporla birebir örtüşmüştür, bu da veri hazırlığının tam olarak tekrarlanabilir olduğunu doğrulamıştır.

3. Model Application

Test setine üç farklı model/konfigürasyon uygulanmış ve karşılaştırılmıştır: (1) orijinal baseline, (2) Optuna ile ayarlanmış (tuned) nokta tahmin modeli, (3) kalibre edilmiş quantile bandı (alpha=0.08/0.5/0.92, tuned hiperparametrelerle). Tümü aynı feature seti ve aynı test dilimi üzerinde çalıştırılmıştır:

```
# Kalibre edilmiş quantile band + tuned hiperparametreler
for alpha in [0.08, 0.5, 0.92]:
    params = dict(TUNED_PARAMS, objective='quantile', alpha=alpha, metric='quantile')
    model = lgb.train(params, lgb_train, num_boost_round=2000,
                      valid_sets=[lgb_valid],
                      callbacks=[lgb.early_stopping(100)])
    preds[alpha] = np.clip(np.expm1(model.predict(X_test)), 0, None)


band = np.sort(np.column_stack(list(preds.values()))), axis=1) # crossing düzeltmesi
```

4. Test Metrics

Nokta tahmin karşılaştırması (baseline vs tuned) ve quantile band kalibrasyon karşılaştırması (üç farklı alpha konfigürasyonu) aşağıda özetlenmiştir. Tüm sonuçlar, hiçbir aramada kullanılmamış gerçek test setinde (136–145. hafta) ölçülmüştür:


Konfigürasyon	Coverage	Pinball (alt/orta/üst)	Crossing
alpha=.10/.90 (orijinal, baseline params)	%75.99	12.00 / 30.18 / 15.81	29 / 32.821
alpha=.05/.95 (geniş, baseline params)	%87.49	7.00 / 30.19 / 9.79	11 / 32.821
alpha=.08/.92 (kalibre, tuned params)	%80.59	10.13 / 29.92 / 13.61	9 / 32.821

Tablo 4 — Quantile band kalibrasyon denemeleri: coverage hedefi (%80) alpha=.08/.92 ile başarıyla yakalanmıştır.



Şekil 4 — Üç alpha konfigürasyonunun coverage karşılaştırması. Orta çubuk (kalibre, %80.59) hedefe en yakın sonuçtur.

Kalibre edilmiş konfigürasyon ($\alpha=.08/.92$ + tuned hiperparametreler) üç açıdan da orijinalden üstündür: coverage hedefe (%80) çok daha yakın (%80.59 vs %75.99), quantile crossing oranı düşmüştür (9 vs 29 satır, yani %0.03 vs %0.09) ve orta (P50) pinball loss'u da hafifçe iyileşmiştir (29.92 vs 30.18) — bu son bulgu, tuned hiperparametrelerin quantile modellerine de fayda sağladığını göstermektedir.



Şekil 5 — Kalibre edilmiş quantile band, örnek bir center/meal kombinasyonunda (10 haftalık test penceresi).

Not: %80.59 sonucu, $\alpha=0.08/0.92$ için test setinde elde edilen tek noktalık bir sonuçtur; α 'nın test setine göre seçilmiş olması (üç farklı değer denenip en iyisinin raporlanması) hafif bir iyimser yanlılık riski taşır. Daha sıkı bir metodoloji için α seçiminin de HPO'daki gibi bir iç-validasyon setinde yapılması önerilir; bu, Sonuç bölümünde bir sonraki adım olarak belirtilmiştir.

5. Model Deployment

Bu turda üretilen üç yeni model artefaktı (tuned_lgb_model.txt, quantile_final_p8.txt, quantile_final_p50.txt, quantile_final_p92.txt) diskte saklanmıştır ve mevcut baseline/orijinal quantile modellerinin yerini alacak şekilde bir sonraki dağıtım adımında kullanılabilir. Deployment kapsamı ve önerileri (haftalık yeniden eğitim, dinamik indirim kuralına bağlanma) önceki fazdaki değerlendirmeye aynı kalmıştır; bu turda yeni bir üretim entegrasyonu yapılmamıştır.

6. Code Implementation

Bu refinement turunda yazılan ve çalıştırılan betikler: notebooks/repro_01_02.py (veri hazırlığı doğrulama), repro_03_baseline.py (baseline doğrulama), refine_01_hpo.py (Optuna araması), refine_02_final_eval.py (tuned model – gerçek test karşılaştırması), refine_03_quantile_calibration.py (3 α konfigürasyonu karşılaştırması), refine_04_final_calibration.py (ince ayarlı final kalibrasyon).

```
def pinball_loss(y_true, y_pred, alpha):  
    diff = y_true - y_pred  
    return np.mean(np.maximum(alpha * diff, (alpha - 1) * diff))  
  
coverage = ((actual >= pred_lo) & (actual <= pred_hi)).mean()  
crossed = np.any(raw_preds != np.sort(raw_preds, axis=1), axis=1).sum()
```

Conclusion

Bu refinement turunda, önceki fazların sonuçları önce bu oturumda birebir yeniden üretilerek doğrulanmış (RMSLE 0.4763, MAE 62.12, Coverage %75.99 — hepsi eşleşti), ardından iki gerçek iyileştirme denemesi çalıştırılmış ve gerçek, daha önce hiç görülmemiş test setinde ölçülmüştür:

- Sızıntısız Optuna hiperparametre araması (40 deneme), test setinde RMSLE'yi %0.20, MAE'yi %0.50 iyileştirmiştir — mütevazı ama gerçek bir kazanım.
- Quantile band kalibrasyonu, orijinal %75.99 coverage'ı hedeflenen %80'e (%80.59) taşımış; aynı zamanda quantile crossing oranını (%0.09 → %0.03) ve P50 pinball loss'unu da hafifçe iyileştirmiştir.

Karşılaşılan zorluklar: (1) HPO çalışma süresi büyük veri setinde (390K+ satır) belirgin olmuş, bu da deneme sayısını (40) sınırlı tutmayı gerektirmiştir; (2) alpha kalibrasyonunun test setine bakılarak seçilmesi hafif bir metodolojik risk taşımaktadır ve ideal olarak ayrı bir kalibrasyon setinde yapılmalıdır; (3) LightGBM'in `feature\_pre\_filter` ayarı farklı `min\_data\_in\_leaf` denemelerinde teknik bir engel oluşturmuş, her deneme için ayrı Dataset nesnesi oluşturularak çözülmüştür.

Sonraki adımlar olarak: alpha kalibrasyonunun ayrı bir iç-validasyon setinde yapılması, walk-forward cross-validation ile sonuçların daha sağlam doğrulanması ve tuned+kalibre modelin dinamik indirim kuralına bağlanarak uçtan uca bir israf azaltım simülasyonunda test edilmesi önerilmektedir.

References

- Kaggle — "Food Demand Forecasting" veri seti (kannanaikkal/food-demand-forecasting).
- Ke, G. ve ark. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS.
- Akiba, T. ve ark. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. KDD.
- Koenker, R. (2005). Quantile Regression. Cambridge University Press.
- Abdullah, N., Shaikh, A. K., & Almusharraf, A. (2025). Towards a sustainable retail food chain: Artificial intelligence driven dynamic pricing and promotions for food waste reduction. Journal of Posthumanism, 5(6), 571–588.
- Proje deposu: github.com/nerminkilicarslan/SIC_AI_17_Capstone_Group_11